

Занятие 2. Введение в анализ данных. Где живут данные?

Магистратура, трек «AI аналитика данных»

Полный пакет материалов для лектора и студента

Главная идея занятия. Это не обзор ресурсов и не раннее погружение в pandas. Пара учит студента принимать первое аналитическое решение: **как найти данные, проверить их происхождение, метаданные, лицензию и ограничения до начала анализа.**

1. Место занятия в треке

Согласно описанию трека, занятие должно познакомить студентов с open data, источниками данных (Kaggle, поисковики датасетов, гос. порталы, API), структурой датасета и правовыми аспектами использования данных, а практическим результатом становится **паспорт найденного датасета**. Именно поэтому занятие выступает мостом между вводной встречей про ИИ-инструменты и последующими лабораторными по очистке, преобразованию и визуализации.

2. Ограничения и рабочие допущения

- Поток может достигать **70 студентов одновременно**.
- Уровень владения кодом у студентов разный, поэтому занятие должно одинаково работать в режимах **code** и **no-code**.
- Преподавательский пакет должен позволять провести пару даже лектору, который понимает логику анализа данных, но не является автором материала.
- Основной очный фокус — на практике; лекционная часть даётся компактно, но внятно и связно.

3. Что должно получиться у студента

К концу пары студент:

1. различает **датасет**, **портал**, **API**, **формат файла**;
2. умеет найти как минимум **три** источника данных по теме;
3. может прочитать базовые метаданные: **владелец**, **дата обновления**, **лицензия**, **формат**, **описание полей**;
4. понимает, что такое **единица наблюдения**;
5. объясняет, почему выбранный источник **пригоден** или **непригоден** для аналитической задачи;
6. оформляет **паспорт датасета**.

4. Состав пакета материалов

Файл	Для кого	Назначение
Master guide (tex/pdf)	Лектор / команда	Основной методический документ: логика занятия, тайминг, активности, критерии, работа с потоком 70 человек.
Lecturer cheatsheet	Лектор	Короткая шпаргалка на одну встречу.
Instructor notebook	Лектор	Colab-ноутбук с slide-like блоками, демонстрациями CSV/JSON/API, подсказками и комментариями для ведения пары.
Student notebook	Студент	Рабочий Colab-лист: мини-примеры, задания, шаблоны ответов, optional code track.
Student longread	Студент / платформа	Короткий текст по ключевым понятиям, который можно выдать до или после пары.
No-code workbook	Студент	No-code шаблон: сравнение 3 источников, чек-лист, паспорт датасета.
HTML passport builder	Студент	Лёгкий автономный HTML-конструктор паспорта датасета.
Program/cluster matrix	Команда курса / лектор	Матрица направлений магистратуры, кластеры потока и стартовые открытые источники по тематикам.

5. Рекомендуемый сценарий пары (90–100 минут)

Время	Блок	Что происходит
0–10 мин	Вход в тему	Кейсовый вопрос: «Вам дали тему анализа, но не дали данные. Как не схватить мусор?». Кратко фиксируются цель пары и конечный артефакт.
10–25 мин	Мини-лекция	Open Data, dataset vs. portal vs. API, единица наблюдения, метаданные, лицензия, правовые ограничения, роль LLM как помощника, а не замены проверки.
25–40 мин	Демо преподавателя	Один CSV, один JSON, один API; затем быстрый реальный поиск источника и разбор метаданных.
40–75 мин	Практика в мини-группах	Группы по 2–3 человека ищут 3 источника по своей теме/кластеру, сравнивают их и оформляют паспорт 1 выбранного датасета.
75–90 мин	Мини-защиты	4–6 коротких выступлений: что выбрали, почему, какой главный риск/ограничение заметили.
+10 мин (опц.)	Буфер / домашнее задание	Разбор типичных ошибок, объяснение домашнего хвоста и критериев сдачи.

6. Лекционная часть: насколько подробно её разрабатывать

Лекционный блок здесь нужен, но **не как длинная автономная лекция**. Оптимальная плотность — 5 компактных смысловых узлов:

1. **Что такое open data и почему аналитик начинает именно с поиска источника.**
2. **Где живут данные:** каталог датасетов, тематический портал, гос. портал, API.
3. **Как выглядит структура данных:** таблица, JSON, документация, описание полей.
4. **Что читать в метаданных:** publisher, дата обновления, лицензия, coverage, формат.
5. **Правовые и этические риски:** персональные данные, ограничения лицензии, отсутствие описания, невозможность воспроизводимости.

Лекция должна быть достаточно подробной, чтобы любой понимающий лектор смог по ней вести пару, но не настолько тяжёлой, чтобы она съела практику.

7. Как вести занятие на потоке около 70 человек

- Не отправлять всех в полностью свободный поиск. Лучше заранее раздать **кластеры тематики и стартовые источники**.
- Работать в **парах/тройках**. Это резко снижает хаос и число вопросов.
- Основной артефакт у всех один и тот же: **паспорт датасета**.
- Для студентов без кода дать полноценный no-code путь: браузер + workbook + HTML builder.
- API показывать всем как идею, но делать обязательным только как **демо** или **опциональный трек**.

8. Code / no-code логика занятия

8.1. Обязательный общий слой

- поиск и сравнение источников;
- анализ метаданных;
- проверка лицензии и ограничений;
- заполнение паспорта датасета.

8.2. No-code путь

- браузер;
- Google Dataset Search / Kaggle / data.gov.ru / тематические порталы;
- Google Sheets или **No-code workbook**;
- **HTML passport builder**.

8.3. Code/light-code путь

- Colab;
- чтение CSV;
- просмотр структуры JSON;
- один GET-запрос к открытому API без авторизации;
- первичная интерпретация полей.

9. Что считать результатом пары

Главный артефакт: паспорт датасета. Нужно проверять не то, “нашёл ли студент ссылку”, а то, **понял ли он, что за данные он собирается использовать.**

Минимальные поля паспорта:

- название набора;
- ссылка на источник;
- тип источника (портал / каталог / API / файл);
- publisher / владелец;
- дата публикации или обновления;
- лицензия / условия использования;
- формат;
- единица наблюдения;
- ключевые поля;
- краткое описание возможной аналитической задачи;
- ограничения и риски.

10. Домашнее продолжение

Домашка должна **продолжать** работу с тем же набором данных, а не создавать новую задачу:

1. довести паспорт до финальной версии;
2. добавить краткое описание полей;
3. подтвердить, каким образом данные будут импортированы (CSV/JSON/API/download link);
4. сформулировать 2–3 возможные аналитические гипотезы;
5. optional: сделать первый импорт в Colab или предпросмотр в таблице.

11. Быстрая рубрика оценки

Критерий	Вес	Что считается хорошим результатом
Релевантность источника	25%	Источник действительно помогает отвечать на заявленный вопрос.
Чтение метаданных	25%	Заполнены publisher, дата, лицензия, формат, описание полей/структуры.
Критическое мышление	25%	Студент видит ограничения, риски и не переоценивает качество данных.
Ясность паспорта	25%	Артефакт читается быстро, структурно и воспроизводимо.

12. Стартовые тематические кластеры для большого потока

Ниже — **сокращённая** версия кластеров. Полный перечень программ и источников вынесен в workbook *lesson02_program_clusters_and_sources.xlsx*.

Кластер	Примеры тем	Стартовые источники
AI, Data Science и разработка ПО	ML/AI, open-source, software engineering, developer ecosystem	Stack Overflow Survey; GH Archive; OpenAlex; Kaggle.
Кибербезопасность, инфраструктура и сервисы	уязвимости, сетевые измерения, инфраструктура	CISA KEV; NVD; RIPE Atlas; CAIDA.
Био, здоровье, химия и foodtech	здоровье, biotech, химия, population indicators	WHO GHO; WHO GHE; World Bank; OpenAlex.
Урбанистика, экология, климат и энергетика	городская среда, климат, устойчивость, энергия	data.gov.ru; NOAA CDO; Data.gov; World Bank.
Инженерия, робототехника, фотоника и производство	сенсоры, робототехника, измерения, производство	NASA Open Data; NOAA/NCEI; UCI ML Repository; Data.gov.
Бизнес, продукт, дизайн и гуманитарные исследования	экономика, продукт, медиа, культура, humanities	World Bank; ECB; Europeana; Google Trends; OpenAlex.

13. Какие вопросы задавать студентам вслух

- Кто собрал эти данные и зачем?
- Что является единицей наблюдения?
- Когда датасет обновлялся в последний раз?
- Есть ли у него лицензия или хотя бы внятные условия использования?
- Можно ли по этим данным ответить на ваш вопрос, или данных недостаточно?
- Что в этом наборе вызывает недоверие?

14. Что не стоит делать на этом занятии

- делать длинный блок про программирование;

- заставлять весь поток проходить через один и тот же сложный API-клиент;
- проверять только «нашли 3 ссылки» без обсуждения качества;
- превращать правовой блок в изолированную сухую лекцию;
- перегружать студентов десятком платформ вместо повторяющегося сценария поиска и оценки.

15. Финальная рекомендация

Лучший формат для этого занятия — **единый педагогический сценарий + две технические дорожки**. Все студенты делают одну и ту же аналитическую работу: **поиск, сравнение, выбор и описание источника данных**. Отличается только инструментальный слой: кто-то делает это через браузер и workbook, кто-то — через Colab и лёгкий код.